

# **Примена фази логике у оцењивању филмова на бази рецензија гледалаца**

Дуња Спасић

*Математички факултет*  
*e-mail: mi16073@alas.matf.bg.ac.rs*

Јелена Јеремић

*Математички факултет*  
*e-mail: mi16062@alas.matf.bg.ac.rs*

## 1. Проблем предвиђања оцене филма

На интернету постоји велики број сајтова за претрагу многих услуга или производа. Такви сајтови обично допуштају корисницима да дају коментар и оцену садржаја који сајт нуди. Проблем којим се овај пројекат бави је додела оцене филму на основу унете рецензије гледаоца. Могуће је, са неким изменама, применити овај програм и на друге врсте услуга. За потребе овог пројекта је коришћен сајт *IMDb* тако што су за базу коментара и оцена су узете рецензије за 18 љубавних филмова. Циљ овог пројекта је да се кориснику предложи оцена коју би могао да да филму на основу коментара који је унео. Овај проблем може да се посматра као проблем класификације.

У раду [1] је сличан проблем решаван применом алгоритама за класификацију података. Аутори су класификовали рецензије филмова у пет класа, од најмање до највише корисне у зависности од заједничких интересовања аутора рецензије и корисника. Примењени су алгоритам Бајесове класификације и неуронске мреже.


Рад [2] се бави анализом поларности осећања у рецензијама филмова написаних на шпанском језику. Аутори су приступили овом проблему техникама истраживања мишљења (енг. *Opinion Mining*) и семантичког оријентисања (енг. *Semantic Orientation*). Истраживање мишљења подразумева сакупљање стварних података и анализу нових података на основу направљене базе па спада у методе надгледаног учења. Семантичко оријентисање је метода која не анализира податке учењем. Овај приступ укључује памћење позитивних и негативних речи, а затим одређује да ли се речи из рецензије налазе у првом или другом скупу. Обе методе имају и предности и мане. Мана истраживања мишљења је што се скуп речи превише ослања на сакупљење податке. С друге стране, мана семантичког оријентисања је потреба за чувањем великих речника, а и недовољна флексибилност алгоритма при промени коришћеног језика. Као и у раду [2], овај пројекат комбинује обе методе.

## 2. Решење проблема коришћењем фази логики

Приликом решавања овог задатка било је потребно формалним, математичким језиком описати природан језик, тј. учинити да програм разуме рецензију написану на природном језику. За решавање проблема изабране су методе фази логики. На основу унете рецензије, одређује се вредност из реалног интервала  $[0,1]$  која представља степен припадности филма скупу добрих филмова. Предност употребе фази логики и функције припадности скупу добрих филмова је елегантно решење ситуације да се рецензијом углавном износе и добре и лоше карактеристике филма, што подразумева да већина филмова неће бити ни потпуно добри ни потпуно лоши. Друга предност оваквог начина оцењивања је што се интервал  $[0,1]$  лако пресликава на оцене од 1 до 10.

На самом почетку *IMDb User reviews* странице су раздвојене тако што су из сваке реченице рецензије сачуване битне речи, тј. избацују се тзв. *stop words*, речи које се често појављују у реченицама али не играју никакву улогу у значењу реченице. Ове речи су садржане у *python* библиотеци *nltk.corpus*. Осим *stop* речи из рецензија су избачени и модификатори, чија ће улога касније да буде објашњена. Парови (*lista bitnih reci*, *ocena komentara*) су формиран на основу рецензија свих 18 коришћених филмова и сачувани у *csv* фајлу. Затим су направљене две мапе, од којих једна садржи све битне речи које се појављују у рецензијама филмова оцењених са 1, 2 и 3, док друга мапа садржи речи које се појављују у рецензијама филмова оцењених са 8, 9 и 10. Кључеви елемената мапа су речи, а вредности су број појављивања у лошим рецензијама и број појављивања у dobrим рецензијама. Ова два скупа речи су условно названа скупом добрих речи и скупом лоших речи у зависности од тога да ли хвале филм или га критикују. За одлучивање да ли реч припада скупу добрих или лоших речи је било пресудно у којим рецензијама се фреквентније појављује. Интуитивно би било узимати разлику те две фреквентности као вредност у мапи, јер ако се реч појављује исти број пута и у позитивним и у негативним коментарима, она може да делује неутрално. Међутим, на основу рецензија је примећено да су се позитивне речи у великом броју јављале у негативним рецензијама у форми негације. Фреквентност појављивања добре речи у лошим коментарима не умањује њен значај као добре речи, па је за вредност узет максимум та два појављивања.

Фази функције припадности су дефинисане трапезоидним функцијама. Функција добрих речи (слика 1. лево) има значајне тачке  $(0,0)$  и  $(110,1)$ , а функција лоших речи (слика 1. десно) има значајне тачке  $(0,1)$  и  $(60,0)$ . Ово значи да како се повећава број појављивања добрих речи у рецензији, тако расте вредност функције припадности скупу добрих филмова, а како расте број појављивања лоших речи тако опада вредност функције припадности скупу добрих филмова.



Слика 1. Функције припадности фази скупу.

Лингвистичке променљиве су променљиве чије су вредности речи природног језика. Вредност ових променљивих може да се повећа или смањи применом модификатора. У природним језицима они обично представљају неке придеве или прилоге. Постоје различите врсте модификатора:

**Концентрациони**, који јачају вредности променљивих уз које стоје тј. утичу тако да вредности функције постану више концентрисане око тачака са већим степеном припадности.

$$\mu_{A'}(x) = \mu_A(x)^{\frac{1}{p}} \text{ за } p \text{ веће од } 1$$

**Дилатациони**, којима се вредност функције припадности смањује.

$$\mu_{A'}(x) = \mu_A(x)^p \text{ за } p \text{ веће од } 1$$

Поред ових постоје још и: контрастни интензификатори, контрастни деинтензификатори, пробабилистички... У даљем раду користићемо прве две врсте модификатора.

У случају проблема рецензија филмова, лингвистичке променљиве су речи које се појављују у рецензијама са високим или ниским оценама, тј. битне речи. Модификатори овде представљају речи које често стоје уз битне речи и додатно их описују, појачавајући или умањујући њихово значење. Модификатори су подељени у три групе, на основу тога колико јачају значење битне речи, а у зависности од тога у коју од те три групе спадају, додељене су им и оцене.

Модификатори који слабије утичу на значење битне речи су оцењени са 2, они који осредње утичу су оцењени са 3, а они који изузетно доприносе јачини битних речи, су оцењени са 4. Модификатори су издвојени у посебан *Python* датотеку ради лакшег рада са њима. Коначна оцена битне речи зависила је од тога да ли реч припада скупу добрих или лоших речи. Уколико реч припада скупу добрих речи и модификатор уз ту реч јача значење речи, тада се оцена  $\mu$  те речи рачунала као  $\mu^{\frac{1}{p}}$  где је  $p$  оцена јачине овог модификатора, а уколико модификатор слаби реч, оцена је рачуната као  $\mu^p$ . Обрнуто се рачунала оцена за реч која припада скупу лоших речи. Ако би се реч нашла у оба скупа, тада је посматрано да ли је већи број речи у тој реченици из скупа добрих или лоших речи.

Обрада самих коментара одвојена је од фази логике. Коментари су бивали прочишћени од речи које нису припадале скупу битних речи, али су такође морали да се чувају и цели коментари како би се вршила провера да ли се уз битну реч налази неки модификатор који би могао променити вредност ове лингвистичке променљиве или реч *not* која у потпуности мења знак вредности функције за ту лингвистичку променљиву. Зарад лакше обраде, скуп прочишћених речи и скуп са сваком речју из коментара су представљени листама. Након разврставања ових речи у одговарајуће листе, скупови су бивали прослеђени главном програму за коначну обраду и доделу оцене коментару.

### 3. Резултати примене решења

Решење је тестирано на рецензијама са оценама из интервала од 4 до 7, с обзиром да је програм обучаваан на рецензијама са најнижим и највишим оценама (од 1 до 3 и од 8 до 9).

Накнадно је уочено да реч *not* не може да се посматрета као модификатор јер она мења целокупно значење коментара, тј. *not* представља логичку негацију, добре битне речи претвара у лоше, а лоше у добре. Негација је имплементирана као  $1 - \mu$ , јер фази функције имају супротне монотоности, а затим се ново  $\mu$  помножи са -1 како би се додало на коначни резултат. Након исправке овог дела, оцене су почеле све боље да осликавају унете рецензије.

Прво су биле тестиране значајне тачке (0,0) и (60,1) за фази функцију добрих речи и (0,1) и (60,0) за фази функцију лоших речи. Пошто се добре речи чешће појављују од лоших, велики број њих је имао фази вредност 1. Ово је лоше када се узму у обзир и модификатори, јер позитивни модификатори на овакве речи не би имали никакав утицај. Зато је у фази функцији добрих речи друга тачка померена на (110,1). Након каснијег обрађивања свих коментара и експерименталних померања крајњих тачака у фази функцијама, закључено је да тачке (110,1) за функцију добрих речи и (60,0) за функцију лоших речи дају најбоље резултате.

Проблем дефазификације је решен на следећи начин: оцене филмова се крећу у сегменту од [1, 10], а укупна оцена  $\mu$  је рачуната као збир свих оцена битних речи подељен са бројем битних речи. Како смо имали и позитивне и негативне рецензије и на основу доделе оцена позитивним и негативним рецензијама, укупан  $\mu$  се кретао у интервалу од -1 до 1. Овај интервал је подељен на 10 једнаких делова тако да уколико би се укупан  $\mu$  нашао у интервалу од -1 до 0, рецензија би била оцењена са неком од оцена из сегмента [1, 5]. Уколико би се укупан  $\mu$  насао у позитивном делу интервала, тада би се рецензији додељивале више оцене, из сегмента [6, 10]. Коришћење интервала [-1,1], тј. одузимања лоших речи и сабирања добрих решава проблем појављивања нових речи које се никада нису појавиле у рецензијама над којима је програм трениран. У таквом случају, таква реч би била оцењена петицом.

Програм је обучаваан на 117 лоших рецензија и 205 веома добрих рецензија. Од укупно 60 рецензија над којима је тестиран тачно је предвиђена оцена 20 рецензија, док се у 28

рецензија предвиђена оцена разликује за 1 од оцене коју је дао корисник. 14 рецензија је прецењено, а 26 подцењено.

#### 4. Дискусија и закључак

У овом пројекту за предлагање оцене филма на основу рецензије корисника коришћене су методе *Opinion Mining* и *Semantic Orientation* имплементиране применом фази логике. 80% оцена на основу рецензија је било превиђено тачно или приближно тачно до на једну оцену разлике. Ово представља врло добар резултат ако се узме у обзир да је програм тестиран на скупу рецензија са средњим оценама од 4 до 7 које је теже предвидети него оцене које су екстремно добре или екстремно лоше. Било би добро оценити успешност овог програма проширењем скупа тестних рецензија на филмове који нису учествовали у обучавању. Ово остаје део плана за будући рад.

### Библиографија

- [1] **G. Dziczkowski, K. Wegrzyn-Wolska** An autonomous system designed for automatic detection and rating of film reviews, 2008
- [2] **María-T. Martín-Valdivia, E. Martínez-Cámara, Jose-M. Perea-Ortega, L. Alfonso Ureña-López** Sentiment polarity detection in Spanish reviews combining supervised and unsupervised approaches *Expert Systems with Applications*, 2013